

COURS D'ANALYSE DE DONNEES EN GEOGRAPHIE

Maxime Foriez

-

Rapport d'activité : Parcours débutant

Par Jeanne LOPEZ, étudiante en première année du Master GAED :
Géopolitique – GEOINT à Sorbonne Université, Paris IV.

Table des matières

Introduction	3
Séance 2. Les principes généraux de la statistique :	3
I. Réponses aux questions de cours :	3
II. Mise en œuvre avec Python	8
2.2 Manipulations	8
Séance 3 : Les paramètres statistiques élémentaires	13
I. Réponses aux questions de cours :	13
II. Mise en œuvre avec Python.....	16
2.2 Manipulations	16
Séance 4. Les distributions statistiques :	19
I. Réponses aux questions :	19
II. Mise en œuvre avec Python	21
2.2 Manipulations	21
Séance 5. Les statistiques inférentielles :	27
I. Réponses aux questions :	27
II. Mise en œuvre avec Python	31
2.2 Manipulations	31
Séance 6. La statistique d'ordre des variables qualitatives :	36
I. Réponses aux questions de cours :	36
II. Mise en œuvre avec Python	38
Indications des problèmes que vous avez rencontrés et comment vous les avez résolus (ou pas) / Indications de vos difficultés d'apprentissage	40
Réflexion personnelle sur les sciences des données et les humanités numériques en fonction des exercices de votre parcours :	41

Introduction

Ce rapport d'activité rend compte des travaux réalisés dans le cadre du cours d'Analyse de Données en Géographie, intégré au parcours de première année du Master GAED : Géopolitique – GEOINT à Sorbonne Université. Ce document synthétise les apprentissages, les manipulations pratiques et les réflexions menées au fil des séances, en mettant l'accent sur l'application des concepts statistiques à des problématiques géographiques.

Chaque séance aborde des thèmes spécifiques, allant des principes généraux de la statistique aux statistiques inférentielles, en passant par l'analyse des distributions statistiques et des variables qualitatives. Les exercices pratiques, réalisés avec le langage Python, illustrent l'utilisation d'outils numériques pour traiter, visualiser et interpréter des données géographiques. Les commentaires et analyses qui accompagnent les résultats visent à éclairer les dynamiques spatiales et à souligner l'importance des méthodes quantitatives en géographie. Enfin, une réflexion personnelle sur les sciences des données et les humanités numériques clôt ce rapport, en soulignant l'enjeu croissant de la maîtrise des outils informatiques pour les géographes. Ce parcours a permis de mesurer l'apport des méthodes quantitatives dans l'analyse des phénomènes spatiaux, tout en identifiant les défis et les apprentissages liés à leur mise en œuvre.

Séance 2. Les principes généraux de la statistique :

I. Réponses aux questions de cours :

1. Quel est le positionnement de la géographie par rapport aux statistiques ?

Pour la géographie, les statistiques sont des outils permettant d'analyser les distributions géographiques et d'interpréter les phénomènes spatiaux. La géographie mobilise les statistiques comme outils de mesure, de description et de comparaison de phénomènes localisés dans l'espace. Les statistiques permettent de quantifier, de décrire et d'expliquer les distributions et les dynamiques spatiales (par exemple, la répartition de la population, l'usage des sols, les flux migratoires, etc.). Les méthodes statistiques sont adaptées pour traiter des variables quantitatives et qualitatives, et pour extraire des paramètres de position, de dispersion et de forme qui caractérisent les phénomènes géographiques.

2. Le hasard existe-t-il en géographie ?

Le hasard existe en géographie, en particulier à travers la notion de variable aléatoire et à travers l'analyse des distributions spatiales. Ainsi, le hasard intervient dans la distribution et la variabilité des phénomènes géographiques, justifiant l'usage de modèles probabilistes. Cela implique qu'une part de hasard est reconnue dans les phénomènes géographiques : leurs variations ne sont pas totalement déterministes.

En statistique, le concept de variable aléatoire est utilisé pour modéliser des phénomènes incertains. Les phénomènes géographiques peuvent être modélisés par des variables aléatoires dont les réalisations sont soumises à des probabilités. Les grandeurs géographiques peuvent être modélisées à l'aide de lois de probabilité, ce qui suppose une part intrinsèque d'aléa dans leur répartition. L'espérance, la variance et l'écart type sont des outils statistiques permettant de mesurer la position et la dispersion des phénomènes, en tenant compte de leur caractère aléatoire.

3. Quels sont les types d'information géographique ?

Les informations géographiques peuvent être de plusieurs types.

Elles peuvent être de type quantitatif. On classe les n valeurs de la série statistique par ordre croissant. Elles sont mesurables, comme la population, la température, la superficie. Au sein de ce type, on trouve des informations dites discrètes, qui sont des valeurs distinctes (ex : nombre de villes). Il existe aussi des informations continues qui sont des valeurs comprises dans un intervalle (ex : altitude). La médiane est le nombre m_e tel que la fréquence cumulée jusqu'à ce que la valeur m soit égale à $\frac{1}{2}$. Les caractères statistiques peuvent être numériques ou catégoriels, et sont utilisés pour décrire les entités géographiques.

Les informations géographiques peuvent également être de type qualitatif et donc descriptives, comme le type de sol, la catégorie d'usage du territoire. Ces informations sont soit nominales (sans ordre entre les modalités) ou *ordinales* (modalités ordonnées).

4. Quels sont les besoins de la géographie au niveau de l'analyse de données ?

Au niveau de l'analyse de données, la géographie a besoin de quantifier les phénomènes pour les comparer et afin d'expliquer leurs relations. Elle a aussi besoin d'analyser et décrire la dispersion, la concentration et la distribution spatiale (par exemple, cartes thématiques, indicateurs statistiques). Ces outils permettent d'identifier l'homogénéité ou l'hétérogénéité d'un territoire. Ces besoins traduisent la volonté de la géographie quantitative de représenter, comprendre et comparer des distributions spatiales complexes.

La géographie utilise également des indicateurs comme la moyenne, la médiane, le mode, la variance, l'écart type, le coefficient de variation, etc. Elle applique aussi des méthodes multivariées pour comprendre les relations entre variables. Cela lui permet de prédire des tendances (comme des modèles de croissances urbaines ou des risques naturels) notamment par la visualisation de données pour faciliter leur interprétation (par l'outil de Systèmes d'Information Géographiques, les cartes et les graphiques). Afin de représenter les données de manière claire et informative, on peut choisir des bibliothèques comme Matplotlib, Seaborn ou Folium pour les cartes interactives.

5. Quelles sont les différences entre la statistique descriptive et la statistique explicative ?

La statistique descriptive vise à résumer et à présenter les données (moyenne, médiane, mode, étendue, quartiles, etc.), sans chercher à établir de relations causales. Les paramètres de position (moyenne, médiane) et de dispersion (variance, écart type), relèvent principalement de la statistique descriptive. Elle répond essentiellement à « comment se présentent les données ? ».

Tandis que la statistique explicative explique les relations entre variables, modélise les phénomènes et prévoit leur évolution (analyses factorielles, régressions, etc.). Elle permet également de tester des hypothèses et à généraliser les résultats à une population plus large (tests statistiques, régressions, analyses multivariées). Elle correspond à l'analyse des structures plus profondes de la distribution, notamment via les moments, l'asymétrie (β_1) et l'aplatissement (β_2).

Elle répond plutôt à « pourquoi les données se distribuent-elles ainsi ? » et « quelles propriétés structurelles révèlent-elles ? »

6. Quelles sont les types de visualisation de données en géographie ? Comment choisir celles-ci ?

Il existe différents types de visualisation, comme la boîte à moustache, appelée aussi boîte de dispersion, (box-plot) qui permet de représenter la dispersion et les quartiles. Quant aux cartes thématiques, ou des représentations en 3D qui permettent de visualiser la répartition spatiale. Enfin, il existe aussi les histogrammes, les diagrammes de dispersion ou encore les courbes cumulatives. Le choix dépend de la nature des données (quantitative ou qualitative), de l'objectif de l'analyse (comparaison, distribution, concentration) et du public visé.

7. Quelles sont les méthodes d'analyse de données possibles ?

Plusieurs méthodes d'analyse de données sont possibles. L'analyse descriptive concerne le calcul de paramètres de position (moyenne, médiane, mode, médiane) qui permettent de résumer les valeurs centrales d'un phénomène, et de dispersion (écart type, variance, étendue, écart interquartile, écart moyen, boîte de dispersion) qui permettent de mesurer la variabilité spatiale. Ces méthodes permettent au géographe de comprendre comment une variable se distribue et quelles particularités elle présente dans l'espace.

Il existe aussi l'analyse multivariée qui permet de faire des analyses factorielles, des classifications ou encore des régressions. Avec l'analyse spatiale, il est possible d'effectuer une étude de la distribution et de la concentration. Enfin, les méthodes graphiques réalisent une visualisation des données pour interprétation.

8. Comment définiriez-vous : (a) population statistique ? (b) individu statistique ? (c) caractères statistiques ? (d) modalités statistiques ? Quels sont les types de caractères ? Existe-t-il une hiérarchie entre eux ?

La population statistique peut être définie comme étant l'ensemble des individus ou des objets sur lesquels porte l'étude (par exemple, l'ensemble des villes d'un pays, des arbres d'une forêt).

L'individu statistique désigne l'unité élémentaire de la population (comme une commune, un habitant). Les caractères statistiques sont les propriétés ou attributs mesurés sur les individus (ex : âge, superficie, catégories). Et les modalités statistiques décrivent des valeurs ou des catégories que peuvent prendre les caractères (ex : « urbain » ou « rural » pour le type de commune).

On peut citer quatre types de caractères qui se différencient entre eux. Les caractères quantitatifs, aussi appelés numériques, concernent par exemple la population. Les caractères qualitatifs sont catégoriels et désignent par exemple le type de sol. Les caractères discrets sont des valeurs séparées et enfin les caractères continus sont des valeurs contenues au sein d'un intervalle.

Il n'existe pas de hiérarchie stricte et absolue, mais certains caractères (quantitatifs) permettent des analyses plus poussées (calculs de moyenne, variance), tandis que les qualitatifs sont utilisés pour des classifications.

9. Comment mesurer une amplitude et une densité ?

L'amplitude d'une série statistique est une mesure de dispersion qui correspond à la différence entre la valeur maximale et la valeur minimale observées dans un jeu de données. Elle est définie par la formule :

$$E = x_{\max} - x_{\min}$$

L'amplitude donne une première indication sur la variabilité des données, mais elle est sensible aux valeurs extrêmes (ou aberrantes). Elle est donc souvent complétée par d'autres indicateurs de dispersion, comme la variance ou l'écart interquartile.

La densité est une mesure utilisée pour décrire la concentration d'un phénomène dans un espace donné. Ainsi, la densité est utilisée dans le cas de variables continues, notamment pour représenter la répartition des effectifs dans des classes d'amplitude différente. En statistique, elle peut désigner la densité de probabilité pour une variable aléatoire continue, notée $f(x)$, qui décrit la probabilité qu'une variable prenne une valeur donnée. Ainsi, la densité représente la répartition de la masse statistique sur un intervalle. Le mode continu est même défini comme le point où la densité est maximale. Elle peut également désigner la densité spatiale, par exemple la densité de population (nombre d'habitants par km²).

10. À quoi servent les formules de Sturges et de Yule ?

Ces deux formules sont utilisées pour déterminer le nombre optimal de classes (ou intervalles) lors de la construction d'un histogramme ou d'une distribution de fréquences, afin de représenter au mieux la structure des données. Elles permettent de choisir un découpage pertinent pour représenter la distribution des données, en évitant d'avoir trop ou trop peu de classes. Ces formules facilitent la lecture et l'interprétation des distributions statistiques.

La formule de Sturges est une méthode empirique qui permet de calculer le nombre de classes k en fonction du nombre total d'observations n :

$$k = 1 + 3.322 \log(n)$$

où $\log$ est le logarithme en base 10. Cette formule est simple et largement utilisée pour des jeux de données de taille modérée. Elle évite de créer trop ou trop peu de classes, ce qui pourrait masquer la distribution réelle des données.

La règle de Yule (ou méthode de la racine carrée) propose un nombre de classes égal à la racine carrée du nombre total d'observations :

$$k = \sqrt{n}$$

Cette méthode est encore plus simple que celle de Sturges et est souvent utilisée pour des distributions uniformes ou lorsque les données sont peu nombreuses.

11. Comment définir un effectif ? Comment calculer une fréquence et une fréquence cumulée ? Qu'est-ce qu'une distribution statistique ?

L'effectif est le nombre d'observations ou d'individus correspondant à une modalité (valeur ou catégorie) d'un caractère statistique. Par exemple, si 10 communes ont une population comprise entre 1000 et 2000 habitants, l'effectif de cette classe est 10. Il peut être absolu (nombre brut d'observations pour une modalité) ou relatif (proportion d'observations pour une modalité par rapport à l'effectif total).

La fréquence est le rapport entre l'effectif d'une modalité et l'effectif total. Elle peut être exprimée en valeur décimale (entre 0 et 1) ou en pourcentage.

$$f_i = \frac{n_i}{n}$$

où n_i = effectif de la modalité i , n = effectif total.

La fréquence cumulée est la somme des fréquences de toutes les modalités inférieures ou égales à une modalité donnée. Elle permet d'étudier la répartition cumulative des données et de savoir quelle proportion de la population a une valeur inférieure ou égale à un certain seuil.

$$F_i = \sum_{j=1}^i f_j$$

Une distribution statistique (ou distribution de fréquences) est une représentation organisée des données, qui associe à chaque modalité (ou classe) son effectif ou sa fréquence. C'est donc la répartition des effectifs (ou fréquences) selon les différentes modalités d'un caractère statistique. Elle peut être présentée sous forme de tableau (modalités, effectifs, fréquences),


d'histogramme (représentation graphique des fréquences) et de courbe cumulative (représentation des fréquences cumulées). Les distributions statistiques permettent de résumer, visualiser et analyser la structure des données, ce qui est essentiel pour toute étude quantitative, notamment en géographie.

II. Mise en œuvre avec Python

2.2 Manipulations


Question 11 : Diagrammes en barres

- Diagramme pour chaque inscrit :



Commentaire sur les résultats obtenus : Ce graphique présente le nombre d'inscrits par département et met en évidence de fortes disparités territoriales. On observe une distribution très hétérogène, avec un petit nombre de départements qui concentrent un volume d'inscrits particulièrement élevé, tandis que la majorité présente des effectifs nettement plus faibles. Les départements les plus peuplés, souvent caractérisés par une forte urbanisation, se distinguent clairement par des barres beaucoup plus hautes, ce qui traduit leur poids démographique et électoral dans l'ensemble du territoire.


- Diagramme pour chaque votant :




Commentaire sur les résultats obtenus : Ce graphique représente le nombre de votants par département et met en évidence une forte variabilité spatiale de la participation électorale en valeur absolue. Comme pour les inscrits, quelques départements se distinguent par un nombre très élevé de votants, ce qui reflète principalement leur poids démographique et leur forte concentration de population. Les départements urbains ou densément peuplés apparaissent ainsi comme des pôles majeurs de mobilisation électorale. Cependant, l'écart observé entre les départements les plus et les moins représentés souligne des disparités territoriales importantes. De nombreux départements affichent un nombre de votants relativement faible, ce qui peut s'expliquer par une population plus réduite mais aussi par des niveaux de participation variables. En comparant ce graphique à celui des inscrits, on peut déduire que la mobilisation électorale n'est pas strictement proportionnelle au nombre d'inscrits, suggérant l'existence de comportements différenciés en matière de participation selon les territoires.

Question 12 : exemple de trois diagrammes circulaires avec les votes blancs, nuls, exprimés et l'abstention pour chaque département


Répartition des votes - Ain



Répartition des votes - Pyrénées-Atlantiques




Répartition des votes - Nouvelle-Calédonie



Commentaire sur les résultats obtenus : Les diagrammes en barres et les diagrammes circulaires produits pour les inscrits et les votants, ainsi que pour montrer le taux de votes blancs, nuls, exprimés et l'abstention, illustrent la répartition des données électorales par département. Ces visualisations permettent de comparer visuellement la participation électorale et les préférences des électeurs entre les territoires. Par exemple, les diagrammes circulaires mettent en évidence la proportion des votes blancs et nuls, offrant une lecture des tendances électorales locales. Ces outils permettent d'identifier les disparités spatiales dans la participation citoyenne et les choix politiques, et peuvent révéler des corrélations entre le contexte socio-économique des départements et les comportements électoraux.

NB : Voir le fichier « Images des diagrammes_Seance_02 » afin d'avoir accès aux autres diagrammes.

Question 13 : Histogramme de distribution des inscrits




Commentaire sur les résultats obtenus : L'histogramme de la distribution des inscrits montre comment les effectifs d'inscrits se répartissent entre les départements. Ce type de graphique permet d'identifier les départements avec une forte ou faible densité d'électeurs inscrits, et de repérer des anomalies ou des valeurs extrêmes. Par exemple, une concentration élevée d'inscrits dans certains départements peut refléter des dynamiques démographiques spécifiques, comme l'urbanisation ou des politiques locales d'inscription électorale.

Bonus : diagrammes circulaires visualisant, pour chaque département, le nombre de voix par candidat

NB : Voir le fichier « Images des diagrammes_Seance_02 » afin d'avoir accès aux diagrammes circulaires de chaque département.

Diagramme circulaire pour l'ensemble de la France :

Répartition des voix par candidat - France entière (1er tour 2022)



Commentaire sur les résultats obtenus : Le diagramme circulaire présente la répartition des voix obtenues par les candidats lors du 1er tour de l'élection présidentielle française de 2022. Deux candidats se détachent clairement avec respectivement 27,8 % et 22,0 % des suffrages exprimés, indiquant une forte polarisation de l'électorat. Les autres candidats obtiennent des scores plus modestes, allant de 23,2 % à 1,6 %.

Séance 3 : Les paramètres statistiques élémentaires

I. Réponses aux questions de cours :

1. Quel caractère est le plus général : le caractère quantitatif ou le caractère qualitatif ? Justifier pourquoi.

Il est possible de classer toutes les variables statistiques en deux grandes catégories : qualitatives et quantitatives. Les variables qualitatives peuvent désigner une qualité, une éventualité non chiffrée, et échappent à la mesure. Quant aux variables quantitatives, elles désignent une quantité ou bien une éventualité chiffrée.

Le caractère le plus général est le caractère qualitatif. Cependant, toute variable quantitative peut être discrétisée et traitée comme qualitative (par exemple, en créant des classes), alors que l'inverse n'est pas toujours possible. Ainsi, cela rend le caractère qualitatif plus général.

2. Que sont les caractères quantitatifs discrets et caractères quantitatifs continus ? Pourquoi les distinguer ?

Les caractères discrets, dits aussi les caractères discontinus, décrivent des listes finies et isolées de valeurs, comme un choix entre « oui » ou « non », le nombre d'enfants, etc. Leur but est de compter les données. Ces variables correspondent à un décompte dans lequel elles ne peuvent prendre que certaines valeurs bien précises.

Les caractères continus décrivent des valeurs prises dans un intervalle, par exemple, l'âge, le salaire, etc. Leur but est de mesurer quelque chose par les données, ce qui implique que ces variables ont une unité. Il existe une infinité de valeurs prises, en général, dans un intervalle réel.

On les distingue car les outils d'analyse et les lois de probabilité associées diffèrent selon le type de variable. Les variables continues permettent des calculs et des tests spécifiques (moyenne, écart type, tests paramétriques), tandis que les variables discrètes sont souvent associées à des décomptes et des diagrammes en bâtons.

3. Paramètres de position

- Pourquoi existe-t-il plusieurs types de moyenne ?

Il existe plusieurs moyennes car chacune est adaptée à différentes distributions (moyenne géométrique, harmonique, etc.) et la moyenne arithmétique suppose une loi normale sous-jacente.

- Pourquoi calculer une médiane ?

La médiane permet de décrire la position centrale d'une distribution, surtout lorsque celle-ci est asymétrique ou contient des valeurs extrêmes qui faussent la moyenne.

- Quand est-il possible de calculer un mode ?

Le mode est calculable lorsque la variable possède une modalité qui apparaît plus fréquemment que les autres. Il est particulièrement utile pour les variables qualitatives ou pour repérer la valeur la plus représentée dans une série.

4. Paramètres de concentration

- Quel est l'intérêt de la médiane et de l'indice de C. Gini ?

La médiale (ou médiane) permet de mesurer la concentration autour d'une valeur centrale. L'indice de Gini mesure l'inégalité ou la concentration d'une distribution (par exemple, la répartition des revenus dans une population).

5. Paramètres de dispersion

- Pourquoi calculer une variance à la place de l'écart à la moyenne ? Pourquoi la remplacer par l'écart type ?

La variance mesure la dispersion globale autour de la moyenne, mais elle est exprimée dans une unité au carré, ce qui la rend moins intuitive. L'écart type, qui est la racine carrée de la variance, ramène la mesure à l'unité d'origine, facilitant l'interprétation.

- Pourquoi calculer l'étendue ?

L'étendue mesure la différence entre la valeur maximale et la valeur minimale d'une série. Elle donne une idée rapide de la dispersion totale des données

- A quoi sert-il de créer un quantile ? Quel(s) est (sont) le(s) quantile(s) le(s) plus utilisé(s) ?

Les quantiles servent à découper une distribution en parties égales (quartiles, déciles, percentiles) pour analyser la répartition des données. Les quartiles et les percentiles sont les plus utilisés.

- Pourquoi construire une boîte de dispersion ? Comment l'interpréter ?

La boîte de dispersion (boîte à moustaches) permet de visualiser la distribution, la médiane, les quartiles et les valeurs extrêmes. Elle aide à repérer la symétrie, l'étendue et les éventuelles valeurs aberrantes.

6. Paramètres de forme

- Quelle différence faites-vous entre les moments centrés et les moments absolus ? Pourquoi les utiliser ?

Les moments centrés mesurent la dispersion autour de la moyenne (ex : variance, asymétrie), tandis que les moments absolus mesurent la dispersion par rapport à zéro. Ils sont utilisés pour caractériser la forme de la distribution (symétrie, aplatissement).

- Pourquoi vérifier la symétrie d'une distribution et comment faire ?

Vérifier la symétrie permet de savoir si la distribution est équilibrée autour de la moyenne. On peut le faire en calculant le coefficient d'asymétrie (skewness) ou en observant la boîte de dispersion.

II. Mise en œuvre avec Python



2.2 Manipulations



Question 5. En reprenant le code précédemment créé dans la séance 2, sélectionner les colonnes contenant des caractères quantitatifs ? Calculer sous la forme d'une liste :


Variable	Moyenne	Médiane	Mode	Écart type	Écart absolu	Étendue	Distance interquartile	Distance interdécile
Type	42271,21	42279	1	24414,57	21148,57	85062	42303	67637,4
Trait de côte (km)	12,82	2,23	0,12	224,7	17,57	39577,14	3,88	13,2
Surface (km ²)	117,72	0,18	0	8997,06	226,71	2117508	0,78	4,87
Latitude	9,58	10,47	-73	97,56	86,9	359,97	189,96	240,24
Longitude	21,17	25,11	22	36,12	30,3	162,8	57,63	98,56

Commentaire sur les résultats obtenus : Le tableau des paramètres statistiques (moyenne, médiane, écart type, etc.) pour les variables quantitatives comme la surface, le trait de côte, ou la latitude, offre une synthèse des caractéristiques centrales et de la dispersion des données. Par exemple, la moyenne et la médiane de la surface des îles permettent de comprendre la taille typique des îles étudiées, tandis que l'écart type révèle la variabilité de ces tailles. Ces indicateurs sont utiles afin de comparer les distributions et identifier des tendances géographiques, comme la concentration des grandes îles dans certaines régions.

Question 8 : À l'aide de Matplotlib et d'une boucle, faire des boîtes à moustache de chaque colonne quantitative. Stocker les résultats dans un dossier img.







Commentaire sur les résultats obtenus : Les boîtes à moustaches (box plots) pour chaque colonne quantitative visualisent la distribution des données, en mettant en avant la médiane, les quartiles, et les valeurs extrêmes. Ces graphiques sont utiles pour détecter les asymétries dans les distributions (comme une queue de distribution allongée pour les grandes surfaces d'îles) et pour comparer la variabilité entre différentes variables. Par exemple, une boîte à moustaches étendue pour le trait de côte pourrait indiquer une grande diversité dans la longueur des côtes des îles.

Séance 4. Les distributions statistiques :

I. Réponses aux questions :

1. Quels critères mettriez-vous en avant pour choisir entre une distribution statistique avec des variables discrètes et une distribution statistique avec des variables continues ?

L'application de la loi discrète et de la loi continue dépend de plusieurs critères qui peuvent dépendre de la nature du phénomène que l'on étudie et également de la forme des données observées.

Le premier critère que l'on peut mettre en avant est la nature du phénomène étudié. On privilégie plutôt une distribution statistique avec des variables discrètes lorsque les valeurs sont

dénombrables et distinctes, comme des résultats de jeux de hasard ou encore des sondages d'opinion. Ces variables prennent en compte des valeurs isolées, comme un nombre de réussites, un nombre de clients, etc. Quant aux variables continues, elles sont utilisées lorsque les valeurs font partie d'un intervalle continu de nombre réelles, c'est-à-dire une variable qui a la capacité de prendre une infinité de valeurs dans un intervalle donné, comme la température ou bien la durée.

La forme de la distribution empirique est aussi un des critères afin de choisir le type de distribution statistique. Ainsi, si la distribution est en escalier (fonction de répartition constante par intervalles), il s'agit d'une variable discrète, contrairement à une distribution qui est lisse qui correspondrait variable continue. On peut également tester la forme de la distribution par l'étude des statistiques inférentielles.

De plus, les caractéristiques statistiques connues permettent de déterminer si une loi donnée est adaptée au jeu de données par des moments (c'est-à-dire l'écart-type, la moyenne ou encore la variance), ce qui permet d'orienter le choix de la loi. Par exemple si la variance est finie et calculable à partir de sommes, cela correspond à la loi discrète alors que si la variance est calculée par les intégrales qui existent alors on utilisera la loi continue.

Le nombre de paramètre est aussi un critère important car une loi composée de plusieurs paramètres s'ajuste mieux à une distribution empirique complexe (il y a donc un nombre de paramètres nécessaires pour modéliser la loi). Il faut prendre en compte plus d'informations pour qu'une loi indépendante de plusieurs paramètres puissent s'adapter à une distribution complexe pour être paramétrée. Par exemple, la loi normale $N(\mu, \sigma)$ qui est une loi à plusieurs paramètres, offre une meilleure approximation des données.

2. Expliquez selon vous quelles sont les lois les plus utilisées en géographie ?

En géographie, les lois probabilistes sont souvent mobilisées afin de décrire la fréquence d'occurrence des phénomènes naturels, la hiérarchie urbaine ou encore la répartition spatiale. On peut citer cinq lois qui sont tout particulièrement utilisés en géographie.

Tout d'abord, les lois de Zipf et la loi de Zipf-Mandelbrot permettent de modéliser les lois rang-taille en géographie. Ainsi, il est possible de déterminer que le rang d'une ville est inversement proportionnel à sa taille (en fonction de sa population). Elle met aussi en avant la distribution des tailles de villes dans un territoire (lois rang-taille) ; la ville la plus peuplée est suivie de villes de plus en plus petites selon une progression régulière. Quant à la loi de Zipf-Mandelbrot, elle ajuste les distributions observées dans certains contextes géographiques. Cela met en avant la régularité hiérarchique des systèmes urbaines et des réseaux géographiques.

La loi log-normale est également fréquemment utilisée en géographie. Elle est aussi connue sous le nom de la loi de Gibrat ou de Galton et elle met en avant qu'une variable suit une loi log-normale si le logarithme de cette variable suit une loi normale. En géographie, elle est généralement utilisée afin de modéliser des phénomènes où la croissance est multiplicative,

comme la distribution des surfaces ou bien par une analyse de la distribution asymétrique des tailles de villes ou des revenus.

La loi de Pareto vérifie la définition d'une fonction de distribution. Elle peut modéliser les phénomènes dans lesquels une petite proportion des causes produit la majorité des effets par le principe des 80/20 (lorsqu'une petite proportion d'unités regroupe la majorité des valeurs totales). De cette manière en géographie, elle décrit des phénomènes à forte concentration et elle permet de visualiser la distribution des richesses ou encore la taille des villes, surtout face aux phénomènes présentant de fortes inégalités ou des valeurs extrêmes.

La loi normale, aussi appelée loi de Gauss, rend possible la modélisation des phénomènes naturels (continus) ou sociaux, souvent autour d'une moyenne, qui résultent de la combinaison de nombreux facteurs indépendants comme la répartition des précipitations ou encor les températures.


La loi de Weibull, la loi de Gumbel et la loi de Benfort font aussi parti des lois qui sont utilisés en géographie puisqu'elles permettent d'étudier des phénomènes géographiques par l'analyse de leur durée, leur vitesse, leur longueur ou encore leur superficie. Ces lois permettent de décrire, modéliser et prévoir la distribution des phénomènes géographiques dans l'espace.

II. Mise en œuvre avec Python


2.2 Manipulations

Question 1 : Utiliser des méthodes `scipy.stats` ou écrire une fonction (informatique) qui vous permettra de visualiser :


- Graphique de la loi de Dirac :




- Graphique de la loi uniforme discrète :




- Graphique de la loi binomiale :



- Graphique de la loi de Poisson :




- Graphique de la loi de Zipf :




Distributions continues :


- Graphique de la loi de Poisson continue :




- Graphique de la loi normale :




- Graphique de la loi log-normale :




- Graphique de la loi uniforme :



- Graphique de la loi du X^2 :



- Graphique de la loi de Pareto :



Commentaire sur les résultats obtenus : Les graphiques des lois statistiques (loi de Dirac, uniforme, binomiale, Poisson, normale, log-normale, Pareto, etc.) illustrent les modèles théoriques sous-jacents aux phénomènes géographiques. Par exemple, la loi de Pareto peut modéliser la distribution des tailles de villes ou des revenus, où une petite proportion d'entités concentre une grande partie de la valeur totale. Ces visualisations aident à comprendre comment les données réelles s'écartent ou se conforment à ces modèles, et à choisir le modèle le plus adapté pour une analyse prédictive ou descriptive.

Séance 5. Les statistiques inférentielles :

I. Réponses aux questions :

1. Comment définir l'échantillonnage. Pourquoi ne pas utiliser la population en entier ? Quelles sont les méthodes d'échantillonnage ? Comment les choisir ?

Un échantillonnage peut être défini comme l'opération qui permet de sélectionner un sous-ensemble représentatif d'une population (la population mère) afin d'analyser les caractéristiques statistiques. Autrement dit, il permet d'étudier les caractéristiques de cette population sans avoir à examiner tous ses éléments. L'échantillon désigne un groupe restreint d'individus ou d'observations qui est prélevé au hasard, ou selon une méthode précise et détaillée, dans une population globale. Un échantillon est représentatif lorsqu'il reflète fidèlement la structure de la population mère.

Un petit échantillon représentatif est préférable à un grand échantillon biaisé, il est souvent inutile ou encore impossible d'étudier la population en entière. Ainsi, un petit échantillon peut fournir des estimations plus fiables qu'un grand échantillon mal constitué qui offrirait des résultats biaisés. De cette manière, la méthode d'échantillonnage aléatoire engendre un coût limité, notamment pour des études dans lesquels on effectue une répétition des tirages. De plus, mesurer tous les individus d'une population peut parfois paraître impossible (matériellement parlant) et certaines données peuvent être inaccessibles.

Il existe plusieurs méthodes d'échantillonnages mais on peut distinguer deux méthodes principales. Tout d'abord, on peut privilégier les méthodes aléatoires (avec le tirage avec remise et sans remise) qui s'appuient sur le tirage au sort (donc le hasard), ce qui garantit que chaque individu a une probabilité connue et non nulle d'être sélectionné. De cette manière, tous les individus ont la même chance d'être sélectionnés. Il existe également des méthodes non aléatoires qui contrairement aux méthodes aléatoires, ne reposent pas sur le hasard mais sur des choix raisonnés et déterminés à l'avance en utilisant d'autres procédés que le tirage au sort. On peut citer la méthode des quotas qui permet d'obtenir des échantillons non biaisés ou encore l'échantillonnage systématique suppose l'existence d'une base de sondage, et qui sont toutes deux des méthodes aléatoires.

On choisit les méthodes d'échantillonnage en fonction de plusieurs facteurs. La taille de la population, la disponibilité des données (et d'une base de sondage exhaustive), le niveau de précision, la nature de la variable étudiée (si cette dernière est ordinale, qualitative, quantitative), les contraintes de coûts et de temps, ou encore le contexte pratique, sont autant de facteurs qui nous font privilégier les méthodes aléatoires ou non-aléatoire.

2. Comment définir un estimateur et une estimation ?

Un estimateur désigne une fonction des données observées et concerne une variable qui est aléatoire. Cette fonction nous aide à évaluer un paramètre inconnu de la population (comme la

moyenne μ , la variance σ^2 , ou une proportion p). Elle désigne donc une variable aléatoire dans le sens où sa valeur change selon l'échantillon. L'estimateur est réellement efficace lorsqu'il est sans biais (quand sa moyenne mathématique est égale à la vraie valeur du paramètre), convergent (il tend vers la vraie valeur du paramètre lorsque la taille de l'échantillon augmente) et de variance minimale (il faut privilégier la plus petite variance parmi les estimateurs sans biais).

En revanche, l'estimation est une valeur numérique. Elle est produite par des données réelles observées de l'échantillon et elle sert d'approximation au paramètre inconnu de la population. Ainsi, la théorie de l'estimation permet d'estimer les paramètres d'une loi de probabilité.

3. Comment distingueriez-vous l'intervalle de fluctuation et l'intervalle de confiance ?

L'intervalle de fluctuation suppose que la vraie proportion théorique p soit connue. C'est un échantillonnage, et non une estimation. On estime un intervalle de fluctuation asymptotique au seuil de 95 % avec un effectif n . Il traduit donc les variations naturelles dues au hasard d'échantillonnage :

$$I = \left[p - z_c \sqrt{\frac{p(1-p)}{n}}, p + z_c \sqrt{\frac{p(1-p)}{n}} \right]$$

Où $z_c = 1.96$ (la valeur critique de la loi normale) pour un seuil de 95 %. Cet intervalle sert à tester une hypothèse : si la fréquence observée f sort de l'intervalle, l'échantillon est jugé atypique.

Au contraire, l'intervalle de confiance est un intervalle construit à partir des données de l'échantillon lorsque le paramètre p (de la population), μ ou σ^2 est inconnu. Il représente l'intervalle dans lequel on estime que ce paramètre se trouve avec un certain niveau de confiance souvent à 95 %. Il traduit l'incertitude liée à l'estimation d'un paramètre à partir d'un échantillon. C'est donc une estimation fondée sur l'échantillon :

$$IC = \left[\bar{X} - z_c \frac{\sigma}{\sqrt{n}}, \bar{X} + z_c \frac{\sigma}{\sqrt{n}} \right]$$

Ses bornes dépendent de la taille de l'échantillon, du risque d'erreur choisi, de l'estimateur et du niveau de confiance.

Si l'on applique l'intervalle de fluctuation et de confiance au sein de Python, elles s'incarnent à travers les modules comme *numpy*, *scipy* ou *pandas*, qui calculent les estimateurs et génèrent des intervalles de confiance.

4. Qu'est-ce qu'un biais dans la théorie de l'estimation ?

Un biais correspond à la différence entre l'espérance de l'estimateur et la valeur à estimer dans la population ; on l'appelle également erreur d'estimation. Autrement dit, il mesure la tendance systématique d'un estimateur à surestimer ou à sous-estimer la valeur du paramètre :

$$B(\hat{\theta}) = E(\hat{\theta}) - \theta$$

Un estimateur est dit sans biais si ce biais est nul :

$$E(\hat{\theta}) - \theta = 0$$

Si cette égalité n'est pas vérifiée, l'estimateur est dit biaisé, et le biais correspond alors à l'erreur systématique introduite par la méthode d'estimation. En Python, les estimateurs biaisés ou non biaisés se traduisent par le paramètre *ddof* dans *numpy.var()* : *ddof=1* qui fournit la variance sans biais d'un échantillon.

5. Comment appelle-t-on une statistique travaillant sur la population totale ? Faites le lien avec la notion de données massives ?

Lorsqu'une statistique travaille sur l'ensemble de la population et non sur un échantillon, elle devient un paramètre (ou parfois une statistique exhaustive). La statistique exhaustive est définie comme une fonction des données qui contient toute l'information possible sur le ou les paramètres de la loi de probabilité de la population.

Ainsi, on peut établir un lien avec la notion de données massives (aussi appelées *big data*) dans le fait que le recensement correspond à une enquête exhaustive qui est un traitement sur la population totale. Il s'agit donc d'une analyse descriptive complète qui porte sur l'ensemble des données disponibles et non plus d'une inférence car il n'y a plus d'incertitude (sans passer par l'échantillonnage et l'estimation). Cette distinction rejoint la notion de données massives car elles permettent dans certains contextes de collecter presque toute la population observée (réseaux sociaux, transactions numériques, géolocalisation).

6. Quels sont les enjeux autour du choix d'un estimateur ?

La recherche du meilleur estimateur d'un paramètre est un problème difficile à résoudre. Les enjeux autour du choix d'un estimateur sont donc multiples. En effet, on choisit un dans un premier temps un estimateur selon la variance de ce dernier : la précision d'un estimateur dépend de sa variance qui doit elle-même demeurer faible afin d'améliorer la précision des résultats et des estimations. Elle permet la conservation de l'information contenue dans l'échantillon afin d'éviter une perte pendant la modélisation. Un estimateur sans biais (de variance minimale) dont l'espérance mathématique coïncide avec la valeur réelle du paramètre, convergent et efficace permet également de garantir l'exactitude d'une moyenne et tend vers la vraie valeur du paramètre lorsque la taille de l'échantillon augmente. L'enjeu de la robustesse

d'un estimateur (mesurer par la notion de point de rupture) est aussi à prendre en compte afin que celui-ci soit peu sensible aux valeurs aberrantes ou extrêmes.

7. Quelles sont les méthodes d'estimation d'un paramètre ? Comment en sélectionner une ?

Il existe plusieurs méthodes d'estimation d'un paramètre. La méthode des moindres carrés en est une, elle est souvent utilisée en régression linéaire. La puissance de cette estimation est maximale lorsque plusieurs variables aléatoires sont étudiées. Elle permet de minimiser la somme des carrés des écarts entre les valeurs observées et les valeurs estimées. L'estimation d'un paramètre par la méthode des moindres carrés se base sur une décomposition analogue :

$$y_i = \hat{y}_i + r_i$$

On peut également estimer un paramètre par la méthode du maximum de vraisemblance (M.V). La vraisemblance offre une approche générale de l'estimation de paramètres inconnus à l'aide de données. La vraisemblance est une fonction des observations et du paramètre dont l'objectif est de trier les différentes valeurs du paramètre selon leur *likelihood* (probabilité en anglais). De fait, cette méthode revient à supposer que l'événement qui s'est produit, était le plus probable. Cette méthode est très courante en statistique appliquée et implémentée directement en Python via les bibliothèques *scipy.stats* et *statsmodels*. Sa fonction est la suivante :

$$V(\theta) = f(y_1, \dots, y_n \mid \theta)$$

La méthode du *bootstrap* est aussi une des méthodes qui permet d'effectuer une estimation qui consiste à rééchantillonner plusieurs fois l'échantillon de départ dans le but d'obtenir un intervalle de confiance pour des paramètres calculables (moyenne, écart type, etc.) ou non calculables (médiane, quartiles, etc.).

La sélection d'une de ces méthodes dépend de plusieurs facteurs. Il faut prendre en compte la nature du paramètre à estimer, la connaissance (ou non) de la loi de probabilité sous-jacente, la taille de l'échantillon (avec la quantité de donnée disponible), la robustesse face aux valeurs aberrantes et enfin la facilité de calcul et de la disponibilité des outils informatiques.

8. Quels sont les tests statistiques existants ? À quoi servent-ils ? Comment créer un test ?

La notion de « test statistiques » peut s'avérer complexe car il existe plusieurs tests statistiques. On peut dans un premier temps distinguer les tests de tests de signification qui sont basés sur un score de test intuitif et le calcul de la p -valeur. Les tests d'hypothèse sont caractérisés par des taux d'erreurs. En revanche, on appelle tests d'hypothèses, tests de signification ou règles de décision, les procédés qui permettent de décider si des hypothèses sont vraies ou fausses, ou de déterminer si des échantillons observés diffèrent significativement des résultats supposés. Il existe aussi les tests paramétriques ou les tests non paramétriques. Pour les tests paramétriques, la forme des distributions testées est supposée connue a priori et le test porte sur la valeur d'un ou plusieurs paramètres d'une loi spécifique. Pour les tests non paramétriques, la forme des

distributions n'est pas prise en considération (en tant qu'hypothèse a priori). D'ailleurs, leur détermination peut être le but du test. Enfin, il existe les tests robustes qui se décomposent en plusieurs catégories (dont en tests libres qui sont valables quelle que soit la forme de la loi de la variable aléatoire X).

Les tests statistiques ont plusieurs fonctions. Ils permettent de comparer un échantillon à une référence théorique (par un test de conformité), de comparer plusieurs échantillons (par un test d'homogénéité) et également de comparer les distributions de deux ou plusieurs séries appariées d'un même échantillon (test sur des séries d'appariées). De plus, ils peuvent montrer qu'une distribution étudiée suit vraisemblablement une loi de probabilité donnée. Il s'agit de vérifier si la distribution de l'échantillon est compatible avec celle de la population mère (c'est un test d'adéquation à une loi de probabilité). Enfin, ils permettent de comparer deux caractères. L'hypothèse H_0 consiste à supposer que les deux caractères quantitatifs ou qualitatifs sont indépendants. Ce test est dit d'indépendance de deux caractères (par un teste d'indépendance de deux caractères).

Plusieurs règles sont à respecter lors de la création d'un test statistique. Tout d'abord, il faut commencer par se poser une question et poser une hypothèse de travail. Ensuite, il faut formuler de façon précise une hypothèse nulle H_0 et hypothèse alternative H_1 afin d'en déduire la loi de distribution d'un paramètre, sous cette hypothèse H_0 . Après cette étape, on peut choisir un seuil d'erreur de probabilité (5 % ou 1 %) avec l'expérience pour accepter H_0 en précisant les conditions d'application du test. Dès à présent, il est temps de collecter les données d'un ou plusieurs échantillons que l'on suppose tiré au hasard dans la population mère (c'est-à-dire représentatif) et de choisir la statistique la mieux adaptée en fonction des caractéristiques de la population étudiée et donner sa loi de probabilité sous les deux hypothèses. On peut ensuite déterminer la région critique (ou région de rejet) de l'hypothèse H_0 au profit de l'hypothèse alternative H_1 et en déduire la règle de décision afin de calculer la valeur numérique t de la variable de décision en utilisant les résultats apportés par l'échantillon. Enfin, il est possible de donner les conclusions du test sur H_0 en fonction du résultat de la comparaison de la valeur de la probabilité p value au risque α .

9. Que pensez-vous des critiques de la statistique inférentielle ?

Les tests statistiques suscitent de nombreuses controverses qui peuvent souvent être la conséquence de tests mal utilisés et mal conçus. On peut compter sept critiques explicites envers tests statistiques. D'après ces critiques, on peut en conclure qu'il vaut mieux privilégier un intervalle correct qu'un test qui n'est pas fiable et qui demeure biaisé.

II. Mise en œuvre avec Python

2.2 Manipulations

Réponses aux questions de la partie « Manipulations » :

1. Théorie de l'échantillonnage

Dans votre rapport, expliquer le lien entre l'intervalle de fluctuation et les valeurs réelles de la population mère. Que pouvez-vous en conclure par rapport aux échantillons utilisés pour le calcul ?

L'intervalle de fluctuation représente la zone où doivent se situer les fréquences échantillonnelles si elles proviennent bien de la population mère avec les proportions observées. Avec un niveau de confiance de 95%, on s'attend à ce que 95% des échantillons prélevés dans cette population aient des fréquences comprises dans ces intervalles.

Dans cet exercice, nous avons comparé les fréquences moyennes à partir de 100 échantillons aléatoires à celles de la population mère. Nous avons dans un second temps calculer les moyennes de chaque modalité (« Pour », « Contre », « Sans opinion ») afin ensuite de les arrondir et de les convertir en fréquences. Ces valeurs représentent les fréquences empiriques issues de l'échantillonnage.

On peut observer dans un premier temps qu'il y a une stabilité des proportions : les intervalles sont relativement étroits (largeur d'environ 6 points de pourcentage), ce qui indique que la taille de l'échantillon ($n=1000$) est suffisamment grande (avec $n=1000$, la marge d'erreur est d'environ $\pm 3\%$, ce qui est acceptable pour une étude d'opinion, les proportions observées sont stables et fiables et que les 100 échantillons sont représentatifs de la population mère.

Si un nouvel échantillon de 1000 personnes est prélevé et que ses fréquences sortent de ces intervalles, on peut suspecter soit un biais d'échantillonnage ou soit un changement réel dans la population mère.

Dès lors, la somme des moyennes arrondies (soit $n = 1000$) a permis de normaliser les résultats et de calculer les proportions moyennes :

- L'opinion "Contre" domine clairement ($41.6\% \pm 3\%$) $\approx 0,42$
- L'opinion "Pour" est légèrement inférieure ($39.1\% \pm 3\%$) $\approx 0,39$
- Les "Sans opinion" sont minoritaires ($19.3\% \pm 2.4\%$) $\approx 0,19$

Ces intervalles supposent que les échantillons sont indépendants et représentatifs. Toute corrélation entre échantillons ou biais systématique invaliderait ces conclusions.

Ces fréquences ont ensuite été comparées à celles de la population mère en calculant l'intervalle de fluctuation au seuil de 95 %. Cela a permis d'obtenir pour chaque proportion p une zone dans laquelle la fréquence observée a 95 % de chances de se situer si les tirages sont aléatoires et représentatifs.

L'échantillon est une représentation partielle et aléatoire de la population mère. Ainsi, toute estimation à partir de celui-ci est soumise à la fluctuation d'échantillonnage. Cette fluctuation exprime le fait que deux échantillons tirés au hasard ne conduisent pas exactement aux mêmes résultats. L'intervalle de fluctuation délimite la zone dans laquelle une fréquence observée dans un échantillon devrait se situer si celui-ci provient bien de la population mère. Si les fréquences empiriques issues de nos calculs se trouvent à l'intérieur de ces intervalles, cela confirme que les échantillons utilisés sont représentatifs et conformes à la loi théorique de la population.

À l'inverse, si une fréquence s'écarte de cet intervalle, cela suggère un biais d'échantillonnage ou une erreur aléatoire importante.

Lorsqu'on observe les échantillons utilisés pour le calcul, on voit qu'il y a un léger écart entre les fréquences moyennes des échantillons et les valeurs réelles de la population mère. Cet écart illustre la fluctuation naturelle des échantillons. Cependant, les fréquences observées restent globalement comprises dans les intervalles de fluctuation à 95 %, ce qui indique que les échantillons utilisés sont statistiquement cohérents et représentatifs de la population mère.

2. Théorie de l'estimation

L'intervalle de confiance ne dépend que de la taille de l'échantillon, c'est-à-dire la somme précédente. Calculez cet intervalle pour chaque opinion. Dans votre rapport, vous interpréterez le résultat obtenu et vous le comparerez avec le résultat précédent.

Avec un niveau de confiance de 95%, on peut affirmer que les vraies proportions de la population mère se situent dans ces intervalles. Concrètement, si on répétait l'enquête 100 fois, environ 95 fois les vraies proportions seraient dans ces intervalles.

L'intervalle de fluctuation (calculé précédemment avec $n=1000$) était plus ÉTROIT car basé sur un échantillon plus grand. Ici, avec $n=\{n_echantillon\}$, les intervalles sont plus larges, reflétant une incertitude plus grande due à la taille d'échantillon réduite. Plus n est petit, plus l'intervalle est large (moins de précision).

Les intervalles de confiance nous donnent une mesure de la fiabilité de nos estimations. Plus l'intervalle est étroit, plus notre estimation est précise. Ici, on peut avoir confiance à 95% que les vraies proportions de la population se trouvent dans ces fourchettes.

On peut représenter ces résultats sous la forme d'un tableau pour se soit plus clair, avec des résultats que l'on a obtenu avec la formule suivante : $IC \text{ à } 95\% = p \pm 1.96 \times \sqrt{p(1-p)/n}$:

Opinion	Fréquence (p)	Intervalle de confiance 95%
Pour	0.39	[0.360 ; 0.420]
Contre	0.42	[0.389 ; 0.451]
Sans opinion	0.19	[0.166 ; 0.214]

On peut valider ces explications en prenant par exemple la première ligne et la 95^e ligne :

- Ligne 1 : Pour=0.379, Contre=0.432, Sans opinion=0.189. Toutes les valeurs se situent dans les intervalles.

- Ligne 95 : Pour=0.370, Contre=0.424, Sans opinion=0.206. Toutes les valeurs se situent dans les intervalles.

Les intervalles de confiance sont identiques aux intervalles de fluctuation calculés. Il y a donc une convergence mathématique car la loi normale (n grand), ces deux intervalles utilisent la même formule et donnent des résultats identiques. 95% des échantillons (environ 95/100) devraient avoir leurs fréquences dans ces intervalles, ce qui est cohérent avec la théorie. On peut affirmer avec 95% de confiance que dans la population totale entre 36% et 42% sont "Pour", entre 38.9% et 45.1% sont "Contre" et entre 16.6% et 21.4% sont "Sans opinion".

3. Théorie de la décision

Vous disposez de deux fichiers Loi-normale-Test-1.csv et Loi-normale-Test-2.csv. Il s'agit d'une série de nombres aléatoires traduisant une distribution statistique. En utilisant la méthode de `scipy.stats shapiro()`. Laquelle est une distribution normale ? — Vous expliquerez dans votre rapport pourquoi.

L'analyse de la normalité d'une distribution constitue une étape dans l'inférence statistique, conditionnant la validité de nombreux tests paramétriques ultérieurs. Le test de Shapiro-Wilk (1965) s'impose comme l'un des tests de normalité les plus robustes pour des échantillons de taille modérée à grande (Royston, 1982). Ce test repose sur le calcul d'une statistique W qui mesure la corrélation entre les quantiles observés et les quantiles théoriques d'une loi normale. On peut établir différentes hypothèses du test :

- H_0 : L'échantillon provient d'une population suivant une loi normale $N(\mu, \sigma^2)$
- H_1 : L'échantillon ne suit pas une distribution normale

Au seuil de signification $\alpha = 0.05$, on rejette H_0 si $p\text{-value} \leq \alpha$.

Voici les résultats du test de Shapiro-Wilk lorsqu'on applique la loi sur les deux fichiers :

Distribution 1 (Loi-normale-Test-1.csv) :

- Statistique W : 0.963948
- P-value : 4.27×10^{-25} (≈ 0)
- Décision : Rejet de H_0 au seuil $\alpha = 0.05$

Distribution 2 (Loi-normale-Test-2.csv) :

- Statistique W : 0.260888
- P-value : $< 2.2 \times 10^{-308}$ (≈ 0)
- Décision : Rejet de H_0 au seuil $\alpha = 0.05$

La première distribution présente une statistique $W = 0.964$, valeur relativement élevée et proche de l'unité, suggérant une concordance avec la loi normale. Néanmoins, la p-value

infinitésimale (≈ 0) conduit au rejet catégorique de l'hypothèse de normalité. Avec $n = 2000$ observations, la puissance statistique du test de Shapiro-Wilk devient considérable. Cette puissance permet de détecter des écarts infinitésimaux par rapport à la distribution théorique, écarts qui seraient indiscernables avec des échantillons de taille réduite. Les caractéristiques observées sont compatibles avec une distribution légèrement leptokurtique (kurtosis positif) ou avec une contamination gaussienne par des valeurs extrêmes.

La seconde distribution se caractérise par une statistique $W = 0.261$, valeur extrêmement faible indiquant une divergence majeure d'avec la loi normale.

Au seuil de signification $\alpha = 0.05$, aucune des deux distributions ne peut être considérée comme suivant une loi normale. Ce résultat, bien que contre-intuitif pour la Distribution 1, s'explique par la conjugaison d'une puissance statistique élevée ($n = 2000$) et de déviations réelles, fussent-elles minimales.

BONUS

Lors du test de la décision, l'une des lois n'est pas normale. En vous aidant de la séance précédente, quelle est sa distribution ?

Lors du test de décision réalisé en séance 05, l'une des lois testées ne suit pas une loi normale. En s'appuyant sur les notions vues lors de la séance 04, on peut affirmer que le TEST 2 ne suit pas une loi normale, et qu'il est plus pertinent de l'associer à une loi exponentielle, ou plus généralement à une loi Gamma. En effet, contrairement à la loi de Poisson, qui modélise des variables discrètes, les données du TEST 2 sont continues, strictement positives et présentent une asymétrie marquée à droite, caractéristiques typiques des lois exponentielles et Gamma. Comme vu en séance 04, ces distributions sont fréquemment utilisées pour modéliser des temps d'attente ou des durées, pour lesquels la loi normale n'est pas adaptée. Le rejet de l'hypothèse de normalité lors du test de décision confirme donc que la distribution sous-jacente n'est pas gaussienne, mais relève d'une loi exponentielle ou Gamma, cette dernière offrant un cadre plus général dont l'exponentielle constitue un cas particulier.

L'examen des statistiques descriptives de la distribution TEST 2 fournit des indices déterminants sur sa nature. La moyenne observée s'établit à 1.188 tandis que la médiane vaut 1.000, révélant une proximité entre ces deux mesures de tendance centrale. Cette caractéristique se distingue nettement de la loi normale, où moyenne et médiane coïncident au centre d'une distribution symétrique. L'étendue des données s'étend d'un minimum strict de 1.000 à un maximum de 14.000, établissant ainsi une amplitude de 13 unités. Cette configuration révèle une asymétrie : l'impossibilité d'observer des valeurs inférieures à 1 suggère l'existence d'une borne inférieure naturelle, propriété incompatible avec la loi normale dont le support théorique s'étend de moins l'infini à plus l'infini. Le coefficient d'asymétrie (skewness) calculé pour cette distribution atteint une valeur fortement positive, de l'ordre de 5 à 6, confirmant la présence d'une asymétrie.

Ainsi, l'analyse menée dans le cadre de cette question permet de conclure que la distribution TEST 2, identifiée comme non-normale par le test de Shapiro-Wilk, suit en réalité une loi

exponentielle. Cette identification repose sur une convergence d'éléments incluant l'analyse des statistiques descriptives révélant une asymétrie positive.

Séance 6. La statistique d'ordre des variables qualitatives :

I. Réponses aux questions de cours :

1. Qu'est-ce qu'une statistique ordinale ? À quel autre statistique catégoriel s'oppose-t-elle ? Quel type de variables utilise-t-elle ? En quoi cela peut matérialiser une hiérarchie spatiale ?

Une statistique ordinale désigne l'analyse de variables qualitatives pour lesquelles un ordre naturel ou croissant peut être établi entre les modalités, mais sans que les écarts entre ces modalités ne soient quantifiables. Elle s'oppose de cette façon à la statistique nominale : elle concerne des catégories sans ordre et sans hiérarchie (comme les couleurs ou les genres). La statistique ordinale s'applique à des variables où les modalités sont hiérarchisées, tels que les niveaux de satisfaction et les classes sociales. Elle utilise donc des variables ordinales qui sont des variables qualitatives dont les modalités peuvent être rangées selon un critère d'ordre. Cette ordination peut matérialiser une hiérarchie spatiale, comme c'est le cas en géographie humaine, où les entités (villes, régions, quartiers) sont classées selon des indicateurs (population, richesse, etc.). Cela permet de déterminer des structures spatiales et des dynamiques territoriales (par l'analyse des dynamiques de montée, stagnation ou déclin des entités dans un système spatial).

2. Quel ordre est à privilégier dans les classifications ?

Dans les classifications, l'ordre à privilégier est l'ordre croissant (qui est l'ordre dit naturel). Cet ordre permet de trouver les valeurs aberrantes (l'identification des valeurs extrêmes, minimales ou maximales), mais également de déterminer l'étude de la loi de la plus grande valeur, et la détection des extrêmes dans une série d'observations. Cependant au sein de certaines lois, il faudra plutôt privilégier l'ordre décroissant selon l'analyse que l'on souhaite mener, comme la loi rang-taille en géographie.

3. Quelle est la différence entre une corrélation des rangs et une concordance de classements ?

Par la corrélation des rangs, on peut mesurer le degré d'association entre deux classements d'un même ensemble d'objets ou d'individus, en évaluant si les rangs attribués par deux classements sont similaires. Ainsi, par la corrélation des rangs on établit une comparaison entre deux classements afin de savoir si ces deux classements sont identiques. C'est ce que permet le test de Spearman qui offre la possibilité de comparer plusieurs variables rattachées à un objet d'étude ou encore de rapprocher et de comparer différents classements urbains. Le test de Kendall qui rend possible la formation de couples de rang selon différents critères.

La concordance de classements, quant à elle, s'intéresse à la proportion de paires d'objets dont l'ordre relatif est le même dans les deux classements (concordant) ou différent (discordant). Autrement dit, elle désigne la généralisation du coefficient de corrélation des rangs de M. G. Kendall. Dans ce cas, les individus ont été classés selon p critères.

La corrélation des rangs donne une mesure globale d'association et compare des classements entre-eux, tandis que la concordance analyse la cohérence des ordres relatifs entre les classements.

4. Quelle est la différence entre les tests de Spearman et de Kendal ?

Le test de Spearman repose sur le calcul du coefficient de corrélation des rangs, basé sur la covariance des rangs attribués par deux classements. Il est souvent utilisé lorsque les rangs sont distincts et ne sont pas ex aequo. Il est souvent utilisé pour sa simplicité et son interprétation intuitive.

Le test de Kendall, quant à lui, s'appuie sur le nombre de paires concordantes et discordantes entre deux classements, et son coefficient (tau) mesure la proportion de concordance. Le test de Kendall est particulièrement utile en présence de rangs ex aequo et peut effectuer une généralisation à plusieurs classements.

Les deux tests sont non paramétriques et permettent d'évaluer l'indépendance ou la similarité entre deux classements.

5. À quoi servent les coefficients de Goodman-Kruskal et de Yule?

Le coefficient de Goodman-Kruskal se base sur la différence William Henry entre les paires concordantes (N_a) et les paires discordantes (N_d) :

$$\Gamma = \frac{N_a - N_d}{N_a + N_d} = \frac{S_C}{S_T}$$

Il mesure l'association entre deux variables ordinales en calculant le surplus de paires concordantes et discordantes. Cette opération est désignée comme étant une proportion. Il est utilisé pour évaluer la force et la direction de l'association dans des tableaux de contingence.


Quant au coefficient Q de Yule, c'est un cas particulier du coefficient de Goodman-Kruskal, appliqué dans le cas des matrices 2x2. Il mesure l'association entre deux variables binaires et dichotomiques. Il varie entre -1 (association négative totale) et +1 (association positive parfaite), et 0 signifie qu'il n'existe aucune association.

Ces coefficients permettent de quantifier l'association dans des analyses de données catégorielles et pour tester l'indépendance statistique. Ces concepts peuvent être implémentés en Python avec des bibliothèques comme `scipy.stats` (pour Spearman/Kendall) ou `statsmodels` (pour des tests plus avancés).


II. Mise en œuvre avec Python

2.2 Manipulations

Question 5 : Visualiser la loi rang-taille en créant une image de sortie



Question 6 : L'image obtenue est illisible. Il vous faut convertir les axes en logarithme. Pour ce, utiliser la fonction locale `conversionLog()` proposée. Elle prend en paramètre une liste.



Commentaire sur les résultats obtenus : La visualisation de la loi rang-taille, notamment après conversion logarithmique des axes, révèle une relation de puissance entre le rang et la taille des entités géographiques (comme les îles ou les villes). Cette loi est fondamentale en géographie pour étudier les hiérarchies spatiales, comme la distribution des tailles de villes dans un pays.

Questions 7. Est-il possible de faire un test sur les rangs ?


Non, il n'est pas possible de faire un test de corrélation des rangs avec une seule variable. Les tests de Spearman et Kendall nécessitent DEUX variables ordinales à comparer. Ici, nous avons uniquement la surface des îles classées par rang (une seule variable). Pour faire un test, il faudrait comparer ce classement avec un autre classement (par exemple : surface versus trait de côte).

Question 14. Dans la bibliothèque `scipy.stat`, utiliser les méthodes `spearmanr()` et `kendalltau()` pour calculer le coefficient de corrélation des rangs et la concordance des rangs. Les deux méthodes prennent en paramètres les deux classements que vous avez respectivement calculés pour le nombre d'habitants et pour la densité. Vous commenterez ce résultat dans votre rapport d'activité.

Pour les populations : Les coefficients très élevés (≈ 0.99) montrent une très forte corrélation entre les classements 2007 et 2025. Les pays les plus peuplés en 2007 le restent en 2025 (Chine, Inde, etc.). Les hiérarchies démographiques sont stables.

Pour les densités : Les coefficients plus faibles ($\approx 0.90-0.95$) indiquent une corrélation forte mais moins stable que pour les populations. Les classements de densité peuvent évoluer davantage (urbanisation, migrations internes).

Bonus 3 : Pour la population mondiale, 1. factoriser le code d'analyse des classements sous la forme d'une fonction renvoyant les coefficients de corrélation des rangs et la concordance des rangs ; 2. faire un algorithme et un code permettant d'analyser la concordance des rangs de l'ensemble des classements annuels de 2007 à 2025



Commentaire sur les résultats obtenus : Les coefficients de corrélation des rangs (Spearman et Kendall) calculés pour les classements de population et de densité entre 2007 et 2025 montrent une forte stabilité des hiérarchies démographiques. Un coefficient proche de 1 indique que les pays les plus peuplés ou denses en 2007 le restent en 2025, confirmant la persistance des structures spatiales à grande échelle. Ces coefficients sont essentiels pour évaluer la cohérence temporelle des classements et identifier des changements structurels, comme l'émergence de nouvelles puissances démographiques.

Indications des problèmes que vous avez rencontrés et comment vous les avez résolus (ou pas) / Indications de vos difficultés d'apprentissage

Difficultés générales : L'ouverture et la lecture des fichiers à l'intérieur de Visual Code étaient parfois compliquées. Ainsi, j'ai dû régulièrement rajouter dans les lignes de codes « encoding= « utf-8 » » afin de spécifier l'encodage des caractères utilisé pour lire ou écrire des fichiers texte. Sans spécifier l'encodage, Python peut utiliser un encodage par défaut qui ne prend pas en charge ces caractères, ce qui peut entraîner des erreurs de lecture ou d'écriture.


```
Exercice > src > seance_02rendu.py
1  # -*- coding: utf-8 -*-
2  """Séance_02
3
4  Automatically generated by Colab.
5
6  Original file is located at
7  | https://colab.research.google.com/drive/1E0Q9bq1p0MFkTAlN7i8cRmeVHSrSSdVT
8  |
9  """
10 #coding:utf8
11
12 import pandas as pd
13 import matplotlib.pyplot as plt
14
15 # Source des données : https://www.data.gouv.fr/datasets/election-presidentielle-des-10-et-20-avril-2022-resultats-definitifs-du-1er-tour/
16 with open("./data/resultats-elections-presidentielles-2022-1er-tour.csv", "r", encoding="utf-8") as fichier:
17     contenu = pd.read_csv(fichier)
```

Séance 06 : Au sein de mes lignes de codes, j'avais tendance pour la 3^e étape (lorsqu'il fallait isoler la colonne Surface et ajouter les continents) à mettre « Surface (km2) », ce qui affichait un message d'erreur et m'empêchait d'isoler la colonne. J'ai alors compris que je devais écrire « Surface (km²) » (comme le montre la capture d'écran ci-dessous). Cette erreur syntaxique m'a montré l'importance des détails dans le codage et l'importance à être précis afin que le code puisse s'exécuter.

```
# 3. Isoler la colonne Surface et ajouter les continents (cast en float)
surfaces = list(files['Surface (km2)'])
surfaces.extend([
    float(85545323), # Asie / Afrique / Europe
    float(37856841), # Amérique
    float(7768030),  # Antarctique
    float(7605049)   # Australie
])
```

Python

Réflexion personnelle sur les sciences des données et les humanités numériques en fonction des exercices de votre parcours :

Au fil des exercices réalisés dans le cadre du cours d'analyse de données en géographie, il apparaît clairement que la digitalisation des données transforme profondément la discipline. Les humanités numériques, qui englobent ce mouvement, rendent possible le traitement massif et automatisé des données géographiques, ouvrant la voie à des analyses plus fines et à des visualisations avancées. L'utilisation de Python et de bibliothèques spécialisées (Matplotlib, Scipy, etc.) dans les exercices montre que la maîtrise des outils informatiques est indispensable : elle permet de manipuler, représenter et interpréter des phénomènes spatiaux complexes. Les difficultés rencontrées (erreurs de syntaxe, choix des méthodes statistiques, interprétation des résultats) soulignent l'importance de la rigueur et de l'apprentissage continu dans ce domaine.

Le cours a mis en avant la nécessité, pour les géographes, de s'appropriier les compétences en sciences des données afin de rester acteurs de l'analyse et de l'innovation dans leur discipline. En somme, les humanités numériques ne remplacent pas la réflexion géographique : elles

l'enrichissent et la prolongent. La capacité à coder et à traiter les données devient un atout majeur pour comprendre les dynamiques spatiales et participer pleinement à l'évolution des sciences humaines. Ainsi, ce parcours m'a permis de comprendre concrètement ce que signifie le mouvement des humanités numériques et pourquoi l'acquisition de compétences en programmation est devenue incontournable pour les géographes.